Modelo Predictivo de Pobreza para Costa Rica

David Rodríguez y Juan Rueda

Sistema de focalización de subsidios sociales - Resultados y recomendaciones

1. Contexto y objetivo

El Banco Interamericano de Desarrollo (BID) contrató a este equipo para desarrollar un modelo de clasificación binaria que le permita al gobierno de Costa Rica identificar hogares en situación de pobreza para asignar subsidios sociales con mayor precisión. La base de datos proviene del sistema SINIRUBE y contiene 143 variables originales, depuradas a 50 tras limpieza, eliminación de redundancias y construcción de 5 variables nuevas.

2. Hallazgos del análisis exploratorio

Distribución del target: Tras binarizar por regla de mayoría por hogar, el 22.9% de hogares es pobre.

Perfil geográfico: Brunca lidera con 35.3% de pobreza, seguida de Pacifico Central (33.3%). La región Central está 5.5 puntos bajo la media nacional. Las zonas rurales presentan una tasa 7 puntos mayor que las urbanas (28% vs 21%).

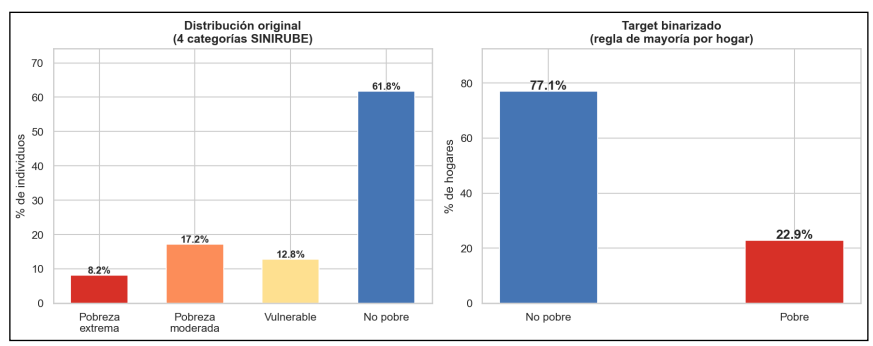

Figura 1. Distribución SINIRUBE (4 categorías) y target binarizado final.

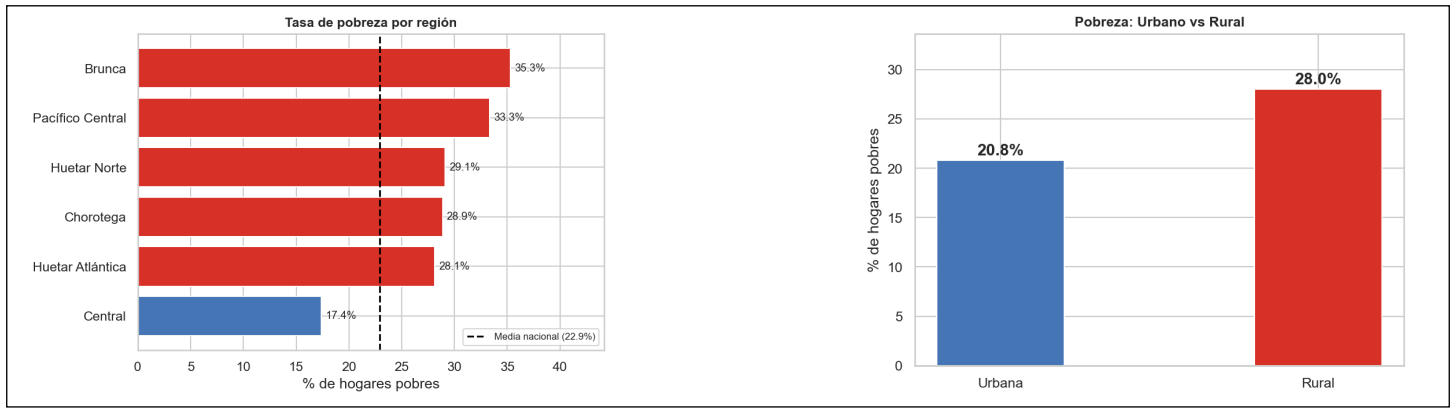

Figura 2. Tasa de pobreza por región geográfica y zona (urbana/rural).

3. Variables construidas

Índice de Activos Tech (suma de nevera, computador, TV, celulares y tablets): siguiendo el enfoque de activos de Filmer & Pritchett, la tenencia de bienes durables tecnológicos es el mejor proxy disponible del ingreso permanente del hogar cuando no se observa directamente el salario.

Privación de Servicios Básicos (conteo de carencias en electricidad, agua, inodoro, combustible y manejo de basura): captura la pobreza desde una dimensión no monetaria, siguiendo la metodología multidimensional del Oxford Poverty and Human Development Initiative (OPHI). Cada carencia suma un punto, reflejando que la acumulación de privaciones agrava el bienestar de forma no lineal.

Calidad de Materiales de la Vivienda (puntaje combinado de paredes, piso y techo): la vivienda inadecuada es un indicador de pobreza estructural crónica. A diferencia del ingreso corriente, los materiales del hogar reflejan la situación acumulada del hogar a lo largo del tiempo y son difíciles de modificar en el corto plazo.

Tasa de Dependencia del Hogar (razón entre dependientes y adultos en edad de trabajar): determina la carga económica per cápita y la capacidad real del hogar de generar ingresos. Un hogar con muchos dependientes y pocos activos laborales enfrenta una restricción estructural de movilidad social.

Hacinamiento Severo (dummy igual a 1 si hay más de 3 personas por cuarto): el hacinamiento extremo está documentado como determinante de peores resultados en salud, rendimiento escolar y bienestar psicológico, lo que perpetúa la pobreza entre generaciones más allá de su efecto inmediato sobre las condiciones de vida.

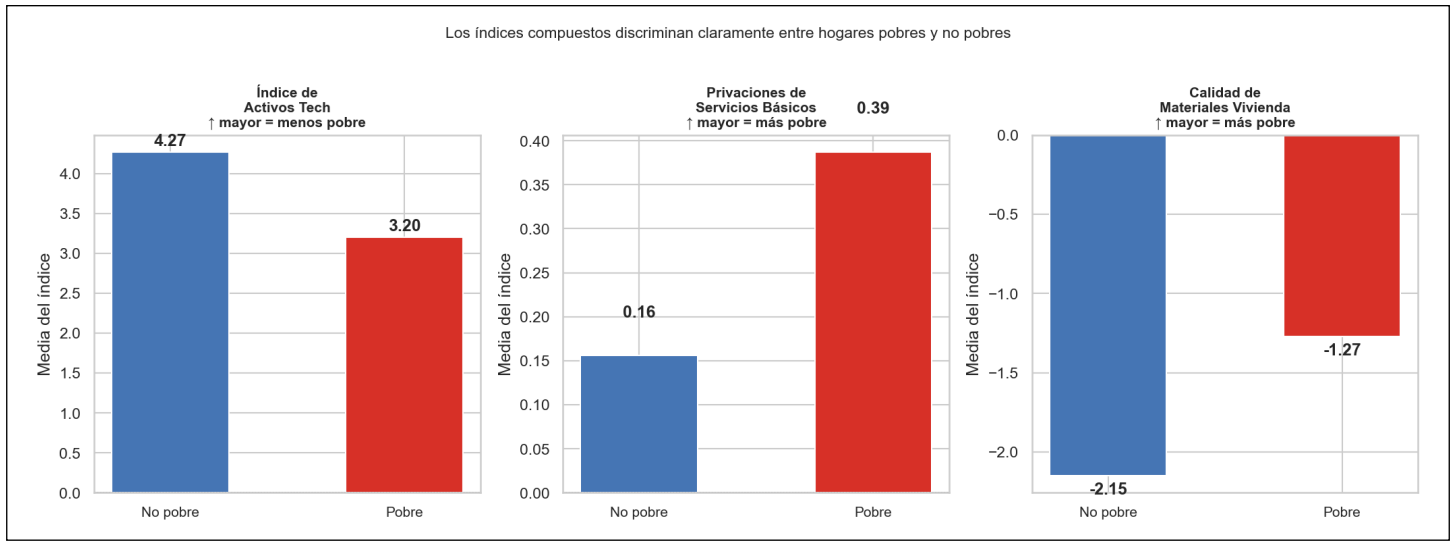

Figura 3. Las tres variables construidas discriminan claramente entre hogares pobres y no pobres.

4. Elección de métrica

Costos:

Falso positivo (Hogar pobre excluido): USD $3.880

Falso negativo (Hogar no pobre incluido): USD $1.350

Métrica seleccionada:

$F_\beta \rightarrow (\beta = 2)$

La métrica F_β combina las métricas *precision* y *recall*. Esta última es crucial en este contexto porque la prioridad es proteger a los hogares más vulnerables. Sin embargo, es importante también tener en cuenta que hay un presupuesto finito. Se establece el β en 2 para priorizar el *recall* que es el objetivo del BID.

5. Elección de modelo y resultado final

Se escogió el modelo de regresión logística con tuning de hiperparametros via GridSearchCV / RandomizedSearchCV (5-fold estratificado, optimizando F_2). El modelo fue evaluado con su umbral optimo de F_2 sobre el conjunto de prueba (80/20 estratificado, semilla fija para reproducibilidad).

Modelo	Umbral	Accuracy	Precision	Recall	F_1	F_2	ROC-AUC
Logit (C=0.01, L2)	0,35	57,9%	34,1%	89,3%	49,3%	**67,5%**	77,5%
Random Forest (700 árboles, max_features = 1))	0,4	53,9%	32,1%	90,3%	47,3%	**66,2%**	77,2%
XGBoost (600 est., max_depth = 3)	0,15	67%	37,3%	64,1%	47,1%	**56%**	74,9%

Las variables más determinantes del modelo en orden de magnitud son:

- Indice de Activos Tech (+)
- Promedio Anos Escolaridad (+)
- Cantidad de Ninos (-)
- Calidad Materiales Vivienda (-)
- Persona con Discapacidad (-)

6. Implicaciones éticas

Hogares mal clasificados: El 10.7% de hogares pobres no es capturado (falsos negativos). Se recomienda un mecanismo de apelación accesible y revisión semestral del modelo.

Sesgo geográfico: Variables de región y zona pueden actuar como proxies de grupos históricamente marginados. Se debe monitorear el desempeño por región para detectar discriminación sistemática.

Interpretabilidad individual: Los coeficientes del modelo permiten explicar, hogar por hogar, que variables determinaron la clasificación, facilitando respuestas concretas a apelaciones ciudadanas.

8. Recomendación

Implementar el **modelo de regresión logística** con umbral 0.35 para maximizar la cobertura de hogares vulnerables. Con F_2 de 67.5% y Recall de 89.3%, supera al PMT vigente y al Random Forest y XGBoost en la métrica objetivo.

El bajo Accuracy (57.9%) y Precision (34.1%) son una consecuencia deliberada del umbral bajo, justificada por la asimetría de costos del programa: excluir un hogar pobre cuesta 2.87 veces más que incluir uno no pobre. Las variables más influyentes son consistentes con la teoría económica del desarrollo, lo que da confianza en que el modelo captura patrones estructurales reales de vulnerabilidad y no ruido estadístico.