Predicciones de Esperanza de Vida

David Rodríguez y Juan Rueda

Consultoría en desarrollo global

1. Contexto y objetivo

El Banco Mundial requiere un modelo cuantitativo que permita predecir la esperanza de vida a partir de indicadores socioeconómicos y de salud pública, con el objetivo de priorizar intervenciones en países de bajos ingresos y evaluar el impacto de políticas sobre la longevidad poblacional. El análisis parte del dataset de la Organización Mundial de la Salud (WHO) que cubre 182 países entre 2000 y 2015 (2,912 observaciones país-año tras limpieza). Se utiliza un split temporal: los años 2000–2012 para entrenamiento (2,366 obs) y 2013–2015 para evaluación fuera de muestra (546 obs), respetando la estructura de panel y evitando fuga de información hacia el futuro.

2. Hallazgos del análisis exploratorio

El análisis de componentes principales sobre los promedios por país revela que PC1 (44% de la varianza) captura el eje de desarrollo: los países con alta esperanza de vida, IDH, escolaridad y gasto en salud se ubican a la izquierda, mientras que los países con alta mortalidad adulta, VIH y desnutrición se ubican a la derecha. **PC2 (16.6%)** separa países por escala demográfica (población, muertes infantiles absolutas, sarampión).

El EDA detectó distribuciones con sesgos fuertes en cuatro variables:
-skew de gdp: 3.2
-hiv_aids: 5.4
-measles: 9.4
-population: 15.9
593 ceros falsos en gasto sanitario como porcentaje del PIB, y alta colinealidad entre thinness_10_19/thinness_5_9 (r=0.94) e infant_deaths/under5_deaths (r=0.997). Estas anomalías motivaron el preprocesamiento descrito en la sección 3.

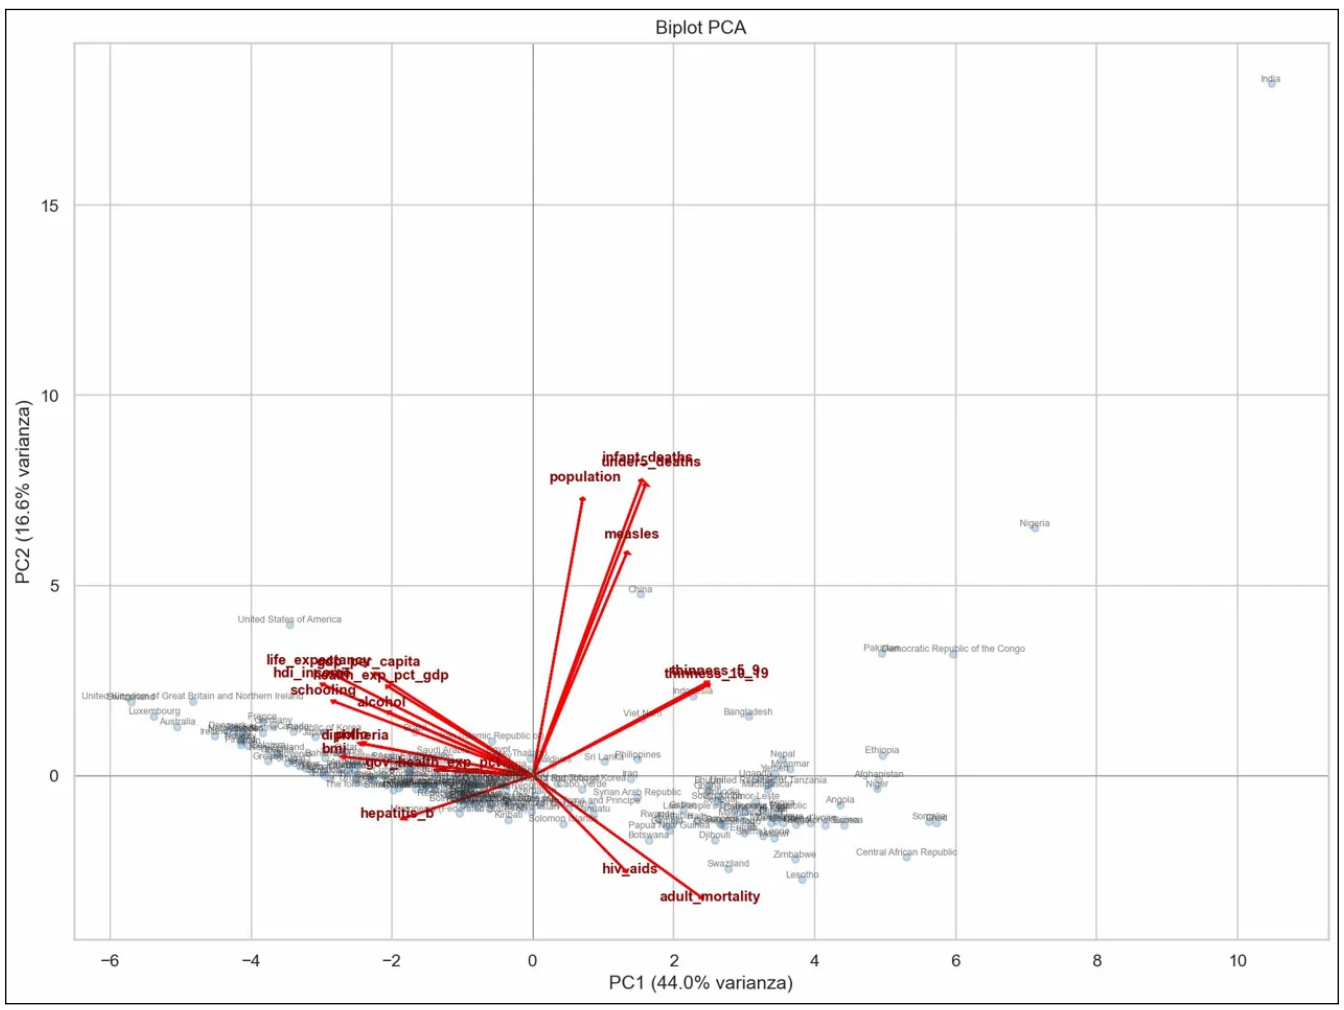
Biplot PCA
PC2 (16.6% varianza)
PC1 (44.0% varianza)
population
measles
alcohol
schooling
hepatitis_b
hiv_aids
adult_mortality
India
Nigeria
China
United States of America
Bangladesh
Ethiopia
Afghanistan
Central African Republic
Zimbabwe
Swaziland
Lesotho
Botswana
Djibouti
Angola
Somalia
Philippines
Sri Lanka
Nepal
Niger
Luxembourg
Australia
France
Germany
Italy
Spain
Portugal
Malta
Cyprus
Iceland
Ireland
Norway
Sweden
Finland
Denmark
Belgium
Netherlands
Austria
Greece
Slovenia
Slovakia
Czech Republic
Hungary
Poland
Estonia
Latvia
Lithuania
Croatia
Romania
Bulgaria
Serbia
Montenegro
Bosnia and Herzegovina
Albania
Turkey
Iran
Syrian Arab Republic
Kuwait
Saudi Arabia
Qatar
Bahrain
Oman
Jordan
Lebanon
Israel
Malaysia
Thailand
Vietnam
Korea
Japan
Mongolia
Kiribati
Solomon Islands
Vanuatu
Papua New Guinea
Fiji
Samoa
Tonga
Cuba
Jamaica
Haiti
Dominican Republic
Guyana
Suriname
Belize
Costa Rica
Panama
Nicaragua
Honduras
Guatemala
El Salvador
Mexico
Canada
Brazil
Argentina
Chile
Uruguay
Paraguay
Bolivia
Peru
Ecuador
Colombia
Venezuela
Mozambique
Madagascar
Malawi
Zambia
Tanzania
Uganda
Kenya
Rwanda
Burundi
Cameroon
Chad
Mali
Mauritania
Senegal
Gambia
Guinea-Bissau
Guinea
Sierra Leone
Liberia
Togo
Benin
Burkina Faso
Ghana
Nigeria
Cote d'Ivoire
Cape Verde
Sao Tome and Principe
Equatorial Guinea
Gabon
Congo
Democratic Republic of the Congo
Pakistan
Myanmar
Timor-Leste
Eritrea
Ethiopia
Somalia
Sudan
Zambia
Namibia
Angola
Botswana
Swaziland
Lesotho
Zimbabwe
Central African Republic
Chad
Niger
Mali
Mauritania
Senegal
Gambia
Guinea-Bissau
Guinea
Sierra Leone
Liberia
Togo
Benin
Burkina Faso
Ghana

3. Preprocesamiento

El pipeline de limpieza comprende cinco etapas principales: (1) eliminación de 10 países con panel incompleto y de South Sudan por exceso de missings; **(2)** imputación manual de población y PIB para 31 países con datos faltantes crónicos mediante series históricas del Banco Mundial; **(3)** función de imputación temporal (interpolación entre años adyacentes) para las variables panel restantes; **(4)** clustering K-Means (k=10) para identificar países similares y aplicar imputación por vecino más cercano dentro del cluster (8 variables, 1,426 valores imputados); **(5)** detección y corrección de valores atípicos por doble criterio IQR (3×IQR por cluster + 1.5×IQR por país), re-imputando 103 observaciones confirmadas.

4. Feature engineering

log_hiv_aids: transformación logarítmica de la carga de VIH/SIDA. Corrige un sesgo de 5.38 que distorsionaba la relación lineal con la esperanza de vida; la correlación con el target mejora de 0.558 a 0.764, la mayor ganancia de todo el feature engineering.

log_gdp_per_capita: transformación logarítmica del PIB per cápita. Corrige un sesgo de 3.20 y eleva la correlación de 0.431 a 0.562, capturando la relación log-lineal entre ingreso y longevidad documentada por la Ley de Preston (1975).

thinness_avg: promedio aritmético de thinness_10_19 y thinness_5_9. Ambas variables presentan una correlación de r = 0.939 entre sí, lo que introduce multicolinealidad sin ganancia predictiva; el índice promedio preserva la señal de desnutrición infantil con una correlación de -0.479 con la esperanza de vida.

vaccination_index: promedio de cobertura de hepatitis B, polio y difteria. Consolida tres variables moderadamente correlacionadas (r = 0.48–0.67) en un único índice de salud preventiva; su correlación con la esperanza de vida (0.459) supera ampliamente a la de hepatitis B por sí sola (0.175).

postneonatal_deaths: diferencia entre under5_deaths e infant_deaths. Las dos variables originales tienen r = 0.997, son casi perfectamente colineales porque la mayoría de muertes menores de 5 años ocurren en el primer año. La diferencia captura la mortalidad de 1 a 4 años, asociada al acceso a agua potable y nutrición, con una correlación de -0.286 con la esperanza de vida, superior a cualquiera de sus componentes por separado (-0.198 y -0.224).

5. Comparación de modelos

Se entrenaron tres modelos con validación cruzada de 5 folds optimizando RMSE. La métrica primaria es el RMSE en el conjunto de prueba (años 2013 - 2015), que penaliza los errores grandes en esperanza de vida, crítico cuando el objetivo es identificar países en situación de rezago severo. El R^2 complementa la lectura indicando qué fracción de la variabilidad entre países y años explica el modelo.

Modelo	R^2	RMSE	Hiperparámetros
Elastic Net (Lasso)	0,88	2,873	α=0.062, L1_ratio=1.0
Random Forest	0,935	2,115	n_est=400, max_depth=22, max_feat=0.4
XGBoost	0,942	1,998	lr=0.08, max_depth=6, subsample=0.7

XGBoost alcanza el mejor RMSE de 1.998 años y R^2 de 0.942, superando al Random Forest (RMSE 2.115, R^2 0.935) y al Elastic Net (RMSE 2.873, R^2 0.880). El error promedio de menos de 2 años en esperanza de vida es suficientemente preciso para orientar políticas públicas, considerando que el rango de la variable objetivo es de 36 a 89 años.

El Elastic Net seleccionó 12 de 16 variables (LASSO puro, l1_ratio=1.0), confirmando que no todas las dimensiones son igualmente relevantes. Su coeficiente estandarizado más alto corresponde a hdi_income (+5.60), seguido de log_hiv_aids (-3.03) y adult_mortality (-1.24).

6. Interpretabilidad del modelo

Los valores SHAP (SHapley Additive exPlanations) permiten descomponer cada predicción en la contribución individual de cada variable, garantizando la interpretabilidad del modelo ante los tomadores de decisiones del Banco Mundial.

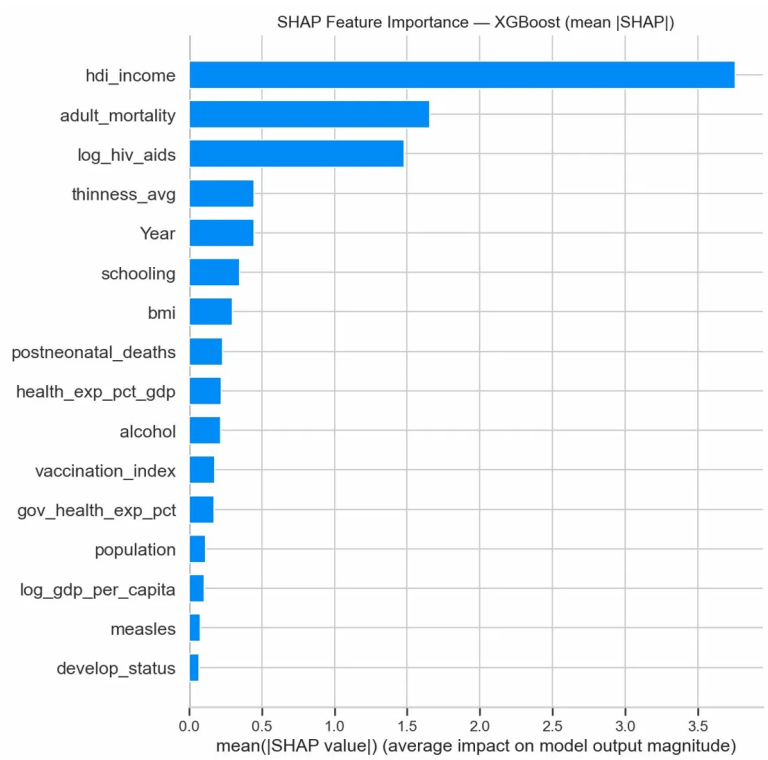

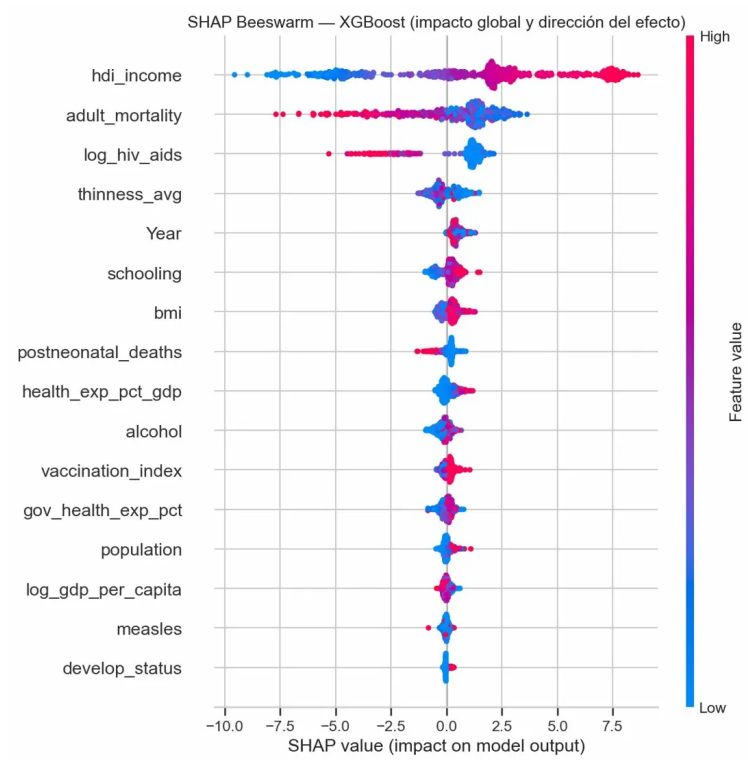

El IDH de composición de ingresos (hdi_income) tiene un impacto SHAP 2.2 veces superior al de la mortalidad adulta y 2.5 veces superior al del VIH/SIDA. Esto sugiere que las intervenciones estructurales sobre ingresos y condiciones de vida tienen mayor retorno en esperanza de vida que las intervenciones sanitarias puntuales, en línea con la evidencia de la Comisión Marmot (2008) sobre determinantes sociales de la salud.

7. Consideraciones éticas

Sesgo de reporte: Los datos faltantes no son aleatorios. Los países en conflicto, con instituciones débiles o con menor capacidad estadística reportan sistemáticamente menos información. La imputación por KNN dentro de clusters de países similares reduce este sesgo, pero no lo elimina. Los resultados para estos contextos deben interpretarse con cautela y complementarse con fuentes alternativas antes de tomar decisiones de política.
Causalidad vs. correlación: El modelo identifica asociaciones estadísticas, no mecanismos causales. El Índice de Composición de Ingresos del IDH (hdi_income) es simultáneamente causa y consecuencia de la esperanza de vida, un problema de endogeneidad que impide atribuirle un efecto causal directo. El modelo no debe usarse para inferir el impacto de intervenciones específicas sin un análisis de causalidad adicional (variables instrumentales, diferencias en diferencias u otros diseños cuasi-experimentales).
Representatividad temporal: El dataset cubre el período 2000–2015. Fenómenos ocurridos después (la pandemia de COVID-19, el retroceso en coberturas de vacunación, el impacto del cambio climático sobre la salud o nuevos brotes epidémicos) no están capturados en el modelo. Extrapolarlo a contextos post-2015 sin reentrenamiento introduce un riesgo significativo de predicciones sesgadas.

8. Recomendación

Se recomienda implementar el modelo **XGBoost** (RMSE=1.998 años, R^2=0.942 en prueba temporal) como herramienta de priorización de países para programas de desarrollo. El modelo explica el 94.2% de la variabilidad en esperanza de vida entre países y años, con un error de predicción promedio inferior a 2 años, precisión suficiente para estratificar países en cuartiles de rezago.